

An Investigation into Econometric Modeling Versus Machine Learning Techniques for Commodity Market Analysis

Ilyes Ben Sassi ¹- 40009961@parisnanterre.fr | Anca-Madalina Cotarta ¹- 40000920@parisnanterre.fr

¹ Authors - Paris Nanterre University | Master 1 Monnaie, Banque, Finance, Assurance : Gestion des Actifs

Avant-Propos

Dans le contexte du cours *Atelier d'économétrie*, sous la direction de M. Tien MOREL, nous avons entrepris une exploration approfondie des modèles économétriques et des techniques d'apprentissage machine appliqués au marché des matières premières. Cette étude se place dans un environnement où l'innovation technologique et la sophistication des méthodes analytiques deviennent cruciales pour comprendre et prédire les dynamiques de marché des matières premières. L'introduction de ce papier vise à examiner l'efficacité relative de ces approches dans un cadre où les exigences de précision et de rapidité d'analyse sont toujours plus pressantes. Il est essentiel de préciser que l'objectif de ce travail n'est pas de présenter des résultats empiriques définitifs. Face à des défis tels que la volatilité des marchés de matières premières et la complexité de leurs interactions avec les facteurs économiques globaux, notre démarche a adopté une méthodologie rigoureuse, combinant théorie économique et innovation en science des données. Notre but est de fournir une compréhension approfondie des modèles analysés, tout en identifiant les limites et défis rencontrés lors de l'application de ces techniques. En explorant en détail notre méthodologie, nous aspirons non seulement à éclairer les mécanismes sous-jacents qui régissent les prix des matières premières, mais également à stimuler une réflexion sur les orientations futures de la recherche dans ce domaine. Cette initiative est guidée par le désir de contribuer de manière significative au débat académique et professionnel, en mettant en lumière les défis et les opportunités associés à l'analyse économique moderne des marchés de matières premières.

Keywords: Econometrics Modeling; Machine Learning; Market Dynamics; Commodities Volatility; Times series Analysis; Structural Breaks

Supervision:

M. Tien MOREL - PhD

Researcher at University of Paris Nanterre
EconomiX-CNRS | m.tien@parisnanterre.fr

Table des matières

I. INTRODUCTION	2
1.1 PRESENTATION DU SUJET.....	2
1.2 IMPORTANCE DE L'ETUDE DANS LE CONTEXTE ACTUEL.....	2
1.3 OBJECTIFS DE LA RECHERCHE	4
1.4 STRUCTURE DU PAPIER.....	4
II. REVUE DE LA LITTERATURE	4
2.1 SYNTHÈSE DES TRAVAUX PRÉCÉDENTS SUR LA MODÉLISATION ÉCONOMÉTRIQUE DES MARCHÉS DE MATIÈRES PREMIÈRES	5
2.2 ÉTUDES SUR L'UTILISATION DES TECHNIQUES D'APPRENTISSAGE MACHINE DANS L'ANALYSE DE CES MARCHÉS.....	5
2.3 IDENTIFICATION DES LACUNES DANS LA LITTÉRATURE EXISTANTE.....	6
III. METHODOLOGIE.....	7
3.1 DESCRIPTION DES DONNÉES UTILISÉES	7
3.2 MÉTHODES ÉCONOMÉTRIQUES UTILISÉES	9
i. Tests de stationnarité.....	9
ii. Tests de cointégration.....	12
iii. Modèles économétriques (e.g., VECM, ARIMA)	16
3.3 TECHNIQUES D'APPRENTISSAGE MACHINE UTILISÉES.....	21
i. Description des modèles de régression (e.g., Lasso, Régression Linéaire)	21
ii. Utilisation de réseaux de neurones (e.g., LSTM).....	23
3.4 CRITÈRES DE COMPARAISON DES MODÈLES.....	26
IV. INTERPRÉTATIONS DES RESULTATS	27
4.1 COMPARAISON PERFORMANCES DES MODÈLES	27
V. CONCLUSIONS.....	28
5.1 LIMITATION DE L'ETUDE ET DÉCOUVERTES	28
5.2 RECOMMANDATIONS POUR LES RECHERCHES FUTURES	29
VI. BIBLIOGRAPHIE	30
VII. ANNEXES.....	31

I. Introduction

1.1 Présentation du sujet

Le marché des matières premières est un élément fondamental de l'économie globale, influençant des secteurs allant de l'agriculture à l'industrie manufacturière et au-delà. Les fluctuations des prix des matières premières peuvent entraîner des répercussions profondes sur les économies nationales, affectant tout, de l'inflation aux politiques monétaires et fiscales. En raison de cette importance capitale, la capacité à analyser et prédire les mouvements de ces marchés est cruciale pour les décideurs économiques, les investisseurs et les planificateurs politiques.

Historiquement, l'analyse des marchés de matières premières a été dominée par des approches économétriques traditionnelles. Ces méthodes, enracinées dans des modèles statistiques rigoureux, utilisent des données historiques pour prévoir les comportements futurs et identifier les tendances sous-jacentes. Les techniques typiques incluent l'analyse des séries temporelles, les tests de stationnarité et de cointégration, et l'emploi de modèles tels que les modèles autorégressifs intégrés à moyenne mobile (ARIMA) et les modèles vectoriels à correction d'erreur (VECM). Ces approches sont appréciées pour leur capacité à modéliser des relations linéaires et à fournir des interprétations claires et directes des dynamiques de marché.

Parallèlement, les progrès récents en matière de techniques d'apprentissage machine ont introduit de nouvelles méthodes pour aborder l'analyse des marchés de commodities. Ces techniques, qui incluent des méthodes de régression avancée comme le Lasso, les machines à vecteurs de support, et les réseaux de neurones profonds tels que les LSTM (Long Short-Term Memory), sont capables de capturer des relations non linéaires complexes et de gérer de grandes quantités de données avec une variabilité élevée. L'apprentissage machine offre des perspectives prometteuses pour améliorer la précision des prévisions en adaptant de manière flexible les modèles aux particularités des données.

Dans ce contexte, ce papier se propose de mener une étude comparative entre les méthodes traditionnelles de modélisation économétrique et les techniques modernes d'apprentissage machine, appliquées à l'analyse des marchés de matières premières. L'objectif est double : évaluer quelle approche délivre les prévisions les plus précises et comprendre comment ces techniques peuvent être intégrées dans les pratiques courantes d'analyse de marché pour améliorer les décisions économiques et financières.

Cette recherche espère ainsi non seulement contribuer au débat académique en offrant une analyse comparative rigoureuse, mais aussi fournir des recommandations pratiques pour les analystes et économistes travaillant dans ou avec le secteur des matières premières. En définitive, l'ambition est de déterminer si les méthodes économétriques traditionnelles restent supérieures ou si, au contraire, les techniques d'apprentissage machine représentent l'avenir de l'analyse économique dans ce domaine crucial.

1.2 Importance de l'étude dans le contexte actuel

L'importance de cette étude réside principalement dans le contexte économique et technologique actuel, caractérisé par une volatilité accrue des marchés de matières premières et une révolution numérique en cours. Les fluctuations des prix des matières premières, telles que le pétrole, les métaux et les produits agricoles, ont un impact direct sur l'économie mondiale, affectant tout, des coûts de production aux prix à la consommation. Le réchauffement climatique est également un facteur déterminant de la dynamique des prix des matières premières.

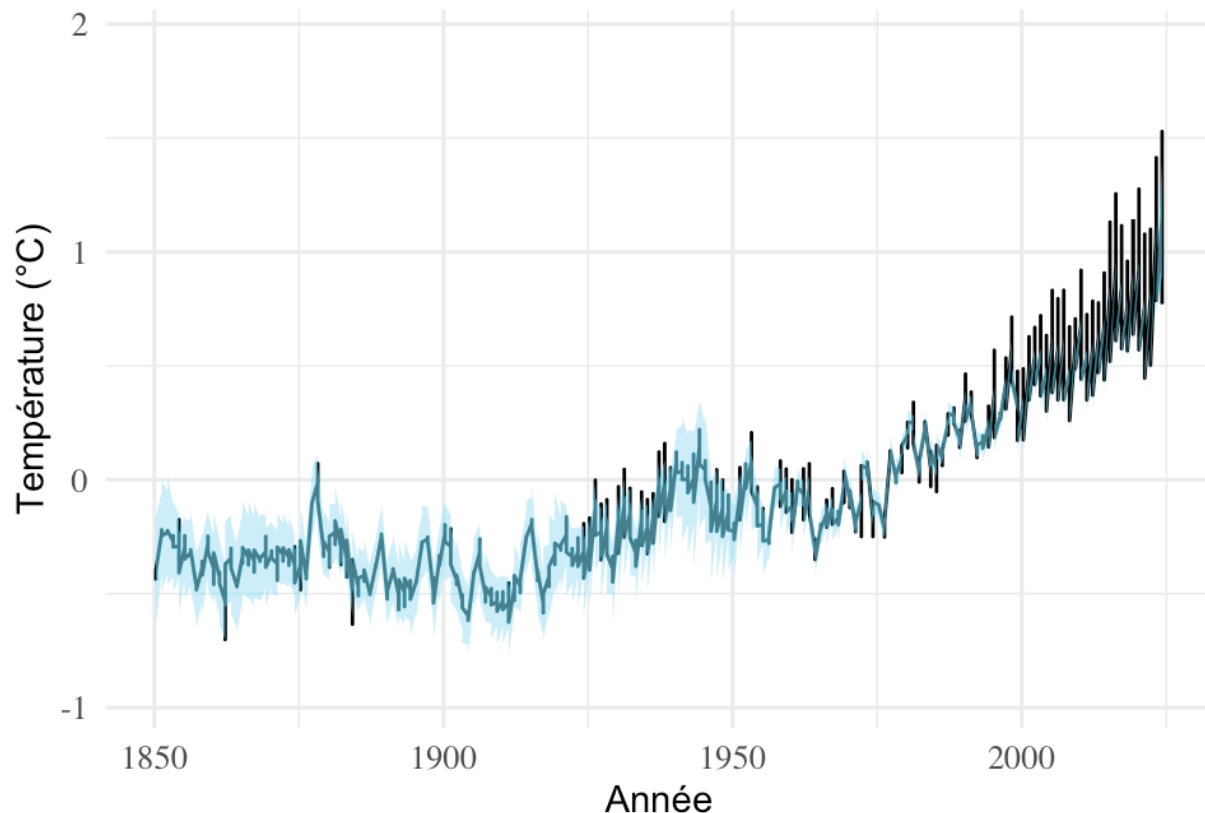


Figure 1: Analysis based on climate data provided by the Met Office Hadley Centre (2023), developed by the authors.

Le graphique susmentionné offre une représentation éloquent du phénomène climatique prédominant, caractérisé par une augmentation progressive de la température moyenne à l'échelle globale. Une analyse approfondie de ce phénomène révèle que cette tendance ascendante est principalement attribuable aux émissions de gaz à effet de serre générées par des nations industrialisées. Cette hausse perpétuelle des températures moyennes mondiales peut être partiellement imputée aux émissions de gaz à effet de serre. Il est primordial de comprendre que ce phénomène n'est pas simplement une conséquence directe de l'activité industrielle, mais résulte également d'un ensemble complexe de facteurs systémiques liés à la manière dont les sociétés modernes consomment les ressources naturelles et déploient l'énergie. Les pays développés, au cœur de cette dynamique, jouent un rôle prépondérant en raison de leur histoire longue d'industrialisation intensive et de leur consommation énergétique élevée par habitant. L'impact des matières premières sur le réchauffement climatique est significatif et multifacette, reflétant la complexité des systèmes de production et de consommation mondiaux. Au cœur de cette problématique, l'extraction et l'utilisation des combustibles fossiles — charbon, pétrole et gaz naturel — représentent les principaux contributeurs aux émissions de gaz à effet de serre, en raison de leur combustion intensive pour la production d'énergie et de chaleur. Cette dépendance aux énergies fossiles s'inscrit dans un cycle de réchauffement auto-entretenu, où l'augmentation des températures globales stimule à son tour une demande accrue en énergie, notamment pour le refroidissement. L'exploitation des matières premières va au-delà des combustibles fossiles et inclut l'agriculture intensive, la déforestation pour l'expansion agricole ou l'extraction minière, et l'exploitation des ressources hydriques. Ces activités contribuent non seulement à la libération directe de gaz à effet de serre, tel que le méthane issu de l'élevage intensif ou de la riziculture, mais aussi à la destruction des puits de carbone naturels, tels que les forêts, essentiels pour séquestrer le CO₂ atmosphérique, ce qui a pour conséquence d'augmenter les catastrophes climatiques et de provoquer une destruction des réserves des matières premières.

1.3 Objectifs de la recherche

Cette recherche vise à atteindre plusieurs objectifs clés qui sont à la fois théoriques et pratiques. Ils sont conçus pour évaluer et comparer l'efficacité des modèles économétriques traditionnels et des techniques d'apprentissage machine dans l'analyse des marchés de matières premières. Le premier objectif est de réaliser une évaluation comparative des méthodes économétriques traditionnelles et des techniques d'apprentissage machine. Cette comparaison vise à déterminer quelle approche fournit les résultats les plus précis et fiables en termes de prévision des prix des matières premières. Cela implique l'analyse de la performance de chaque méthode face à des jeux de données historiques et actuels. Un autre objectif est de comprendre en profondeur les avantages et les inconvénients de chaque technique. Cela comprend l'évaluation de la facilité d'implémentation, la capacité de gestion des grandes quantités de données, la sensibilité aux variations du marché, et la clarté des résultats obtenus. Le troisième objectif consiste à identifier les meilleures pratiques en combinant les forces de la modélisation économétrique et des techniques d'apprentissage machine. Il s'agit de déterminer comment les différentes méthodes peuvent être intégrées dans les pratiques actuelles d'analyse de marché pour améliorer la prise de décision stratégique chez les analystes et les décideurs. En se basant sur les résultats de la recherche, un objectif crucial sera de fournir des recommandations sur la façon d'améliorer les modèles existants. Cela pourrait inclure des suggestions pour l'intégration de nouvelles variables, l'ajustement des paramètres des modèles, ou l'adoption de nouvelles technologies de données tel que l'adoption de modèle hybride. Enfin, cette étude aspire à enrichir la littérature académique dans le domaine de l'analyse économique des matières premières. Les résultats de la recherche pourraient aider les futurs chercheurs et praticiens à mieux comprendre quelles approches sont les plus adaptées pour analyser les marchés de matières premières dans un contexte de plus en plus data-driven.

1.4 Structure du papier

Le présent papier est organisé de manière à offrir une analyse systématique et approfondie des méthodes de modélisation économétrique et des techniques d'apprentissage machine dans le cadre de l'analyse des marchés de matières premières. Après cette introduction, la revue de littérature suit, fournissant un aperçu des travaux antérieurs, et posant les bases théoriques nécessaires à l'entente des deux paradigmes d'analyse considérés. La section suivante, méthodologie, détaille les méthodes de collecte de données, les modèles employés, et les procédures analytiques adoptées pour conduire cette recherche. Analyse des données présente ensuite les résultats obtenus à travers l'application des méthodes mentionnées, analysant leur efficacité et précision dans la prévision des tendances du marché. La section de discussion relie ces résultats aux objectifs de recherche initiaux, en discutant des implications et des limites observées, et en suggérant des pistes pour des travaux futurs. La conclusion de cette recherche synthétise les découvertes majeures et met en évidence leur contribution au domaine économique et académique. La bibliographie fournit des références complètes, tandis que les annexes contiennent tout matériel supplémentaire pertinent pour étayer l'argumentation.

II. Revue de la littérature

2.1 Synthèse des travaux précédents sur la modélisation économétrique des marchés de matières premières.

Les modèles économétriques traditionnels ont historiquement joué un rôle prédominant dans l'analyse des marchés de matières premières, exploitant les fondements de la théorie économique couplés à des méthodologies statistiques avancées. Ces modèles sont essentiels pour discerner les variables influençant les prix des matières premières et pour anticiper leurs évolutions futures.

Modèles à Séries Temporelles

Au cœur des approches économétriques, les modèles à séries temporelles sont privilégiés pour leur capacité à analyser les données historiques des prix, permettant de déceler des tendances persistantes et des motifs saisonniers. Des méthodes telles que l'Analyse des Séries Temporelles Autorégressives Intégrées à Moyenne Mobile (ARIMA), les Vecteurs Autorégressifs (VAR), et les Modèles Vectoriels à Correction d'Erreur (VECM) sont fréquemment utilisées. Ces modèles se fondent sur l'assomption de stationnarité, facilitant l'analyse prédictive à long terme. [Showalter et Gropp \(2019\)](#) ont appliqué ces modèles aux données du marché boursier américain pour évaluer la validité de l'hypothèse de marché efficace, démontrant comment la présence ou l'absence de stationnarité peut affecter la capacité des marchés à intégrer toutes les informations disponibles. Intégrant les dynamiques fondamentales telles que l'offre et la demande, les coûts de production, et les conditions macroéconomiques, les modèles économétriques structurels visent à fournir une explication exhaustive des fluctuations des prix des matières premières. Les modèles à équations simultanées et les modèles basés sur les agents sont couramment cités dans cette catégorie ([Créti, Joëts, & Mignon, 2013](#)).

Les modèles à cointégration examinent les relations à long terme entre les prix des matières premières et d'autres variables économiques clés. La technique de cointégration de Johansen représente une méthode largement adoptée dans ce domaine et qui constitue une méthode courante d'analyse économétrique des marchés de matières premières ([Chengyi Tu, Ying Fan, Jianing Fan, 2019](#)).

Les modèles économétriques traditionnels, bien que fondamentaux pour l'analyse des marchés de matières premières, présentent certaines limitations notables. Premièrement, ils peinent à capturer les relations non linéaires entre les variables. En se fondant sur des interactions linéaires, ces modèles peuvent ne pas saisir pleinement la complexité des marchés de matières premières, limitant ainsi la précision de leurs prédictions. Deuxièmement, ils sont sensibles aux changements structurels dans l'environnement économique ou réglementaire. Ces changements peuvent affecter la validité des modèles, nécessitant des ajustements réguliers pour maintenir leur pertinence. Troisièmement, l'intégration de grandes quantités de données non structurées représente un défi pour ces modèles. À l'ère du big data, leur capacité à traiter efficacement ces informations est souvent limitée, ce qui peut entraver leur utilité dans des analyses contemporaines où rapidité et précision sont primordiales. Ces contraintes mettent en évidence la nécessité de développer des approches plus sophistiquées et adaptatives pour mieux répondre aux exigences des marchés modernes.

2.2 Études sur l'utilisation des techniques d'apprentissage machine dans l'analyse de ces marchés.

L'adoption des techniques d'apprentissage machine représente une évolution significative dans l'analyse des marchés de matières premières, offrant des outils avancés pour décrypter des modèles complexes et non linéaires au sein des données. Ces méthodes se distinguent par leur capacité à améliorer substantiellement la précision des prévisions de prix.

Les réseaux de neurones artificiels, inspirés par le fonctionnement du cerveau humain, sont capables d'apprendre et de modéliser des relations complexes à partir des données. Les réseaux de neurones récurrents, en particulier ceux de type LSTM (Long Short-Term Memory), sont idéalement adaptés à l'analyse des séries temporelles. [M. Magris, M. Shabani et A. Iosifidis \(2022\)](#) illustrent cette capacité en démontrant l'efficacité des réseaux neuronaux bayésiens bilinéaires dans la prédiction des dynamiques de prix sur les marchés à ordres limités. Leur méthode, enrichie par la théorie bayésienne, traite avec

une flexibilité notable les incertitudes des prévisions de marché tout en gérant des données complexes et variées, permettant de palier aux difficultés rencontrés par l'économétrie classique.

Les arbres de décision segmentent les observations selon leurs caractéristiques pour identifier les facteurs clés influençant les prix. [Jonas Rotschi Hanetho \(2023\)](#) explore l'utilisation de l'apprentissage profond pour optimiser les stratégies de trading de matières premières. En appliquant des algorithmes de politique de gradient, il montre que ces modèles peuvent s'ajuster en temps réel aux conditions du marché, permettant d'optimiser les performances de trading tout en minimisant les risques. Cette étude met en lumière l'efficacité de l'apprentissage machine dans la navigation des marchés volatils et sa supériorité par rapport aux méthodes traditionnelles. Les algorithmes d'apprentissage par renforcement permettent aux modèles d'évoluer par essais et erreurs dans un environnement simulé, s'avérant particulièrement utiles pour affiner les stratégies de trading. Cet auteur souligne également leur applicabilité dans ce contexte.

Parallèlement, [M.Narajewski, F. Ziel et R. Weron \(2018\)](#) ont étendu les capacités des modèles économétriques traditionnels en intégrant des techniques de régression pénalisée (statistiques avancées) telles que Lasso, Ridge et Elastic Net pour prédire les prix de l'électricité sur le marché intra journalier allemand. Leur recherche démontre que ces approches avancées sont particulièrement efficaces dans les contextes où les données présentent une forte saisonnalité et des anomalies, offrant ainsi des prévisions plus robustes et résistantes à l'overfitting. Les techniques d'apprentissage machine offrent plusieurs avantages par rapport aux modèles économétriques traditionnels, notamment la capacité à capturer des relations non linéaires, une adaptabilité accrue face aux changements structurels, et une compétence à intégrer et analyser de vastes ensembles de données non structurées. Ces caractéristiques les rendent extrêmement précieuses pour l'analyse avancée des marchés de matières premières, où elles fournissent des insights plus profonds et des prévisions de prix améliorées. Nous discuterons des limites de ces modèles en conclusion de ce papier.

2.3 Identification des lacunes dans la littérature existante.

Bien que des avancées notables aient été réalisées dans l'emploi des modèles économétriques et des techniques d'apprentissage machine pour l'analyse des marchés de matières premières, plusieurs lacunes persistent dans la littérature existante. Un domaine particulièrement sous-exploré concerne l'intégration efficace des prédictions linéaires issues des modèles traditionnels avec les capacités non linéaires des méthodes modernes. [A. Kraevskiy A.Prokhorov et E.Sokolovskiy \(2024\)](#) ont abordé cette question en développant des systèmes d'alerte précoce utilisant des forêts aléatoires pour anticiper les changements de régime dans les marchés émergents. Toutefois, des recherches complémentaires sont requises pour comprendre comment ces techniques peuvent être systématiquement intégrées et optimisées. De plus, la littérature actuelle manque souvent d'analyses sur l'impact des variables exogènes telles que les décisions politiques ou les crises économiques sur les modèles de prévision, malgré leur influence cruciale sur les dynamiques de prix. Les recherches sur les modèles économétriques traditionnels n'explorent pas suffisamment l'intégration de l'apprentissage machine pour améliorer les performances, ce qui représente une lacune majeure. Des approches hybrides¹¹ qui marient les forces de ces deux paradigmes pourraient être une piste de recherche fertile.

¹¹ : *modélisation hybride consistant à combiner les résultats statistiques issus du ML dans les modèles économétriques (et inversement).*

De même, ces modèles s'appuient principalement sur des données historiques structurées et manquent d'attention aux données non structurées, comme les actualités et les données issues des médias sociaux, qui pourraient enrichir significativement l'analyse des marchés. Les marchés de matières premières sont

influencés par une multitude de facteurs interagissant de façon complexe, et le développement de modèles économétriques plus sophistiqués capables de capturer ces interactions pourrait résoudre ce problème. Par ailleurs, les modèles d'apprentissage machine, souvent perçus comme des "boîtes noires", posent des défis en termes de compréhension de leurs mécanismes décisionnels et de l'évaluation de leur fiabilité. Le développement de techniques plus transparentes et interprétables constitue un champ de recherche essentiel. Ces modèles peuvent également s'adapter excessivement aux données d'entraînement et échouer à généraliser sur de nouvelles données, nécessitant ainsi des méthodes pour éviter le sur-apprentissage et améliorer la généralisation des modèles.

L'efficacité de l'apprentissage machine est tributaire de l'accès à des données abondantes et de qualité. Améliorer les méthodes de collecte et de traitement des données pourrait surmonter cette limitation. Enfin, les études tendent à comparer ces modèles sur des ensembles de données et des périodes spécifiques, ce qui restreint la portée de leurs conclusions. Des comparaisons plus rigoureuses et systématiques sur diverses données et contextes seraient nécessaires. En conclusion, malgré les progrès réalisés, des efforts supplémentaires sont nécessaires pour exploiter pleinement les capacités des technologies avancées dans l'analyse des marchés de matières premières.

Notre recherche actuelle se propose donc de constituer une première approche introductive sur le développement des modèles hybrides, qui permettent d'intégrer les forces des approches traditionnelles et modernes pour offrir des outils d'analyse plus efficaces et précis.

III. Méthodologie

3.1 Description des données utilisées.

Dans le contexte de ce projet de recherche, nous analysons des données de prix extraites de contrats à terme sur matières premières, plutôt que des données issues du marché au comptant. Cette orientation méthodologique est dictée par l'objectif d'approfondir notre compréhension des facteurs et des dynamiques qui régissent les prix dans les marchés de contrats à terme. Ces derniers sont prédominants parmi les instruments financiers utilisés par les opérateurs de marché et offrent un reflet précis du comportement des acteurs économiques.

Pour notre étude, nous avons sélectionné l'intervalle temporel s'étendant du 7 septembre 2021 au 31 janvier 2024. Ce choix est motivé par plusieurs facteurs significatifs : premièrement, nous avons observé une modification substantielle dans la dynamique des prix des matières premières dans le sillage de la période post-COVID-19, caractérisée par une volatilité exacerbée. De plus, cette période a été marquée par une incertitude économique accrue, notamment en raison du conflit en Ukraine, qui a exercé une influence considérable sur les prix des matières premières. Bien qu'une extension de la période d'observation aurait pu enrichir notre analyse en fournissant une perspective plus étendue sur ces phénomènes, une telle démarche dépasse le cadre de ce document et pourrait être envisagée dans des recherches ultérieures. Pour garantir une uniformité dans les comparaisons entre les différentes variables, nous avons standardisé l'ensemble des données. Cette démarche consiste à centrer et réduire chaque variable, nous permettant ainsi de disposer d'un jeu de données homogène, propice à des comparaisons équilibrées et précises.




Figure 2: Visual representation of variables using commodities prices futures (daily) – developed by the authors.




Figure 3: Matrix of correlation – developed by the authors.

Dans le cadre de notre projet, nous avons recours à deux ensembles de données distincts : le premier ensemble comprend les données originales non modifiées, tandis que le second a été soumis à un processus de centrage et de réduction. Cette standardisation des données facilite l'implémentation de modèles de machine learning ultérieurs. Nous conservons ces deux jeux de données séparément afin de répondre à divers besoins, notamment pour la réalisation de tests statistiques ou pour l'adoption de modèles de modélisation spécifiques. Nous n'avons pas rencontré de difficultés significatives en ce qui concerne les valeurs manquantes. Celles-ci ont été identifiées et résolues lors d'une analyse plus approfondie des variables, à l'aide d'une méthode de validation croisée des données. Cette technique implique la combinaison de multiples sources de données pour constituer un ensemble cohérent et fiable, permettant ainsi d'éviter des anomalies dans les résultats statistiques.

La matrice de corrélation, telle que déployée dans notre étude, repose sur le coefficient de corrélation de Pearson, une mesure qui présume l'existence de relations linéaires entre les variables. Cependant, cette méthode peut ne pas saisir pleinement les dynamiques non linéaires potentiellement présentes entre les variables étudiées. Il aurait été techniquement avisé de compléter cette approche par l'application du coefficient de corrélation de rang de Spearman, qui, en mesurant les relations monotones, aurait pu enrichir notre analyse en offrant des perspectives supplémentaires sur les interdépendances variables. Malgré cette reconnaissance des limites méthodologiques inhérentes à l'approche de Pearson, notre recherche a continué en se limitant à cette dernière pour l'élaboration des matrices de corrélation, principalement en raison de contraintes liées au cadre et aux objectifs initiaux de notre étude.

La corrélation la plus marquée dans notre étude, d'ordre positif, est observée entre les prix à terme des oranges et ceux du cacao, ainsi qu'entre les oranges et le sucre. Cette relation positive peut suggérer que ces marchés partagent des facteurs communs de demande ou sont affectés de manière similaire par des variables macroéconomiques telles que les changements climatiques, les politiques commerciales, ou des fluctuations saisonnières. En revanche, la corrélation négative la plus significative est celle entre les prix à terme du palladium et ceux des oranges, ce qui pourrait indiquer que ces produits répondent de manière opposée à certains chocs économiques ou tendances de marché. Par exemple, une augmentation de l'activité industrielle pourrait stimuler la demande de palladium, utilisé principalement dans les catalyseurs pour automobiles, tout en ayant peu ou pas d'impact sur les marchés agricoles comme celui des oranges.

3.2 Méthodes économétriques utilisées

i) Tests de stationnarité

Les variables économiques et financières sont généralement des réalisations de processus non stationnaires. La non-stationnarité peut aussi bien concerner l'espérance (moyenne) que les moments du second ordre (variance).

Les cas de non-stationnarité en moyenne, auxquels nous nous limiterons dans le cadre de cours, sont analysés à partir de deux processus (**Nelson et Plosser, 1982**) : les **processus TS** (trend stationary) caractérisés par une non-stationnarité de nature déterministe et les **processus DS** (difference stationary) dont la non-stationnarité est de nature stochastique.

En présence de non-stationnarité, les propriétés asymptotiques usuelles des estimateurs ne sont plus valables et il est nécessaire de développer une théorie asymptotique particulière. Dans un cadre multivarié, elle conduit également à des régressions fallacieuses.

Définition des processus aléatoires stationnaires au sens faible :

Le processus Y_t est stationnaire au second ordre ou faiblement stationnaire si :¹

$$E(X_t^2) < \infty \forall t \in Z \quad (1)$$

$$E(X_t) = m \forall t \in Z \quad (2)$$

$$Cov(Y_t, Y_{t+h}) = \gamma_h \forall t \in Z \quad (3)$$

En résumé Y_t est stationnaire au second ordre si sa moyenne et sa variance (finie) et sa covariance sont indépendantes du temps.

Dans l'analyse de séries temporelles pour les marchés des commodités, l'un des prérequis fondamentaux avant de procéder à des modélisations plus complexes est de s'assurer donc de la stationnarité des données. Cela est crucial car de nombreux modèles économétriques et techniques de prévision, comme les modèles ARIMA (AutoRegressive Integrated Moving Average) et les modèles VAR (Vector Autoregression), supposent que les séries sont stationnaires. L'utilisation de données non stationnaires peut conduire à des modèles peu fiables et à des prévisions erronées.

Il existe un grand nombre de tests de racine unitaire. Les travaux pionniers en la matière sont ceux de Fuller (1976) et Dickey et Fuller (1979, 1981). Ces travaux ont donné naissance à deux tests (DF et ADF) qui sont des tests paramétriques reposant sur l'estimation d'un processus autorégressif.

Un certain nombre de critiques ont conduit à l'élaboration d'autres tests de racine unitaire : **Test de Phillips et Perron** (1988), **Test de Perron** (1989) et **Test de Zivot et Andrews** (1992) en présence de rupture structurelle, **Test de Schmidt-Phillips** (1992) et **Test de Elliot, Rothenberg et Stock** (1996), et le **Test de Kwiatkowski, Phillips, Schmidt et Shin** (1992).

Pour tester la stationnarité, on a fait le choix d'effectuer le test de Dickey-Fuller augmenté (ADF) qui est également utilisé pour prendre en compte également l'autocorrélation des résidus. Ce test vise à déterminer si une série temporelle a une racine unitaire, une caractéristique d'une série non stationnaire. Le test formule l'hypothèse nulle que la série possède une racine unitaire (non stationnaire) contre l'hypothèse alternative que la série est stationnaire.

Test de Dickey-Fuller augmenté (ADF)

Intuition de l'approche de Dickey et Fuller (DF) : soit $\Delta Y_t = \vartheta Y_{t-1} + \varepsilon_t$, avec $\vartheta = \rho - 1$

$\rho = 1$ ou $\vartheta = 0$ signifie que la série Y_t est non stationnaire.

L'apparition d'une autocorrélation des résidus de la régression associée au test DF est une situation courante (*par construction*). Il convient dès lors de traiter ce problème pour 2 raisons évidentes :

- Le test DF suppose que le terme d'erreur est un bruit blanc ;
- Campbell et Mankiw (1987) ont montré que la présence de racine unitaire ne suffit pas pour conclure à un phénomène de mémoire infinie (conséquences permanentes d'un choc).

¹ Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*

Pour traiter le problème d'autocorrélation des résidus, on introduit dans le modèle initial, l'endogène retardée (avec autant de retards nécessaires au "blanchissement" des résidus). Le choix du nombre de retards p est crucial car l'inclusion d'un nombre insuffisant de retards peut affecter le niveau de test. Par ailleurs, un nombre trop élevé de retards réduit le nombre de DDL et donc la puissance du test, conduisant de manière erronée au non-rejet de l'hypothèse nulle.

Les hypothèses du test unilatéral gauche sont : $H_0 : \vartheta = 0$ contre $H_1 : \vartheta \neq 0$

Trois modèles sont à distinguer dans le test séquentiel ADF en pratique :²

1. Modèle (1) : modèle avec constante et tendance déterministe

$$\Delta Y_t = \alpha + \beta_t + \vartheta Y_{t-1} + \sum_{j=1}^p \varphi_j \Delta Y_{t-j} + \varepsilon_t$$

2. Modèle (2) : modèle avec constante sans tendance

$$\Delta Y_t = \alpha + \vartheta Y_{t-1} + \sum_{j=1}^p \varphi_j \Delta Y_{t-j} + \varepsilon_t$$

3. Modèle (3) : modèle sans constante ni tendance

$$\Delta Y_t = \vartheta Y_{t-1} + \sum_{j=1}^p \varphi_j \Delta Y_{t-j} + \varepsilon_t$$

Ainsi, contrairement aux règles de décisions habituelles pour les tests bilatéraux, la règle est inversée :

$t_\varphi > t_{DF}^3$: on ne rejette pas H_0 , il y a présence de racine unitaire

$t_\varphi < t_{DF}$: on rejette H_0 , il y a absence de racine unitaire

Résultats obtenus

L'ensemble des matières premières examinées, telles que le Maïs, le Gaz, l'Or et le Pétrole brut (WTI), présentent des résultats indiquant une non-stationnarité. Cela signifie que leurs prix sont influencés par des tendances à long terme et des cycles qui varient dans le temps. Ces caractéristiques peuvent être attribuées à divers facteurs économiques tels que les fluctuations de l'offre et de la demande, qui affectent les prix des commodités agricoles comme le Maïs, le Soja et le Blé. Ces fluctuations peuvent résulter de changements saisonniers, de conditions météorologiques, de politiques agricoles et de variations de la demande globale. En outre, des facteurs géopolitiques et économiques tels que les événements géopolitiques, les décisions politiques des grands producteurs de pétrole et les variations des niveaux de production influencent souvent les prix du Pétrole brut et du Gaz naturel. Les influences macroéconomiques, comme les incertitudes économiques ou les variations des taux d'intérêt, peuvent faire fluctuer les prix de l'Or et de l'Argent, souvent considérés comme des valeurs refuges.

Logique économique des résultats

Les résultats obtenus reflètent les attentes dans un contexte de marchés des matières premières où les prix sont extrêmement sensibles à une multitude de facteurs externes. L'absence de stationnarité dans l'ensemble des matières premières illustre le fait que ces marchés sont non seulement influencés par des

² Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*

³ Les tables avec les valeurs critiques de Dickey Fuller sont présentes en annexes.

conditions de marché immédiates mais également par des tendances économiques à long terme et des chocs externes.

ii) Tests de cointégration

Dans la partie précédente de notre analyse, nous avons examiné la stationnarité des séries temporelles des prix des différentes commodities. Ayant constaté que l'ensemble de ces séries sont non stationnaires, il devient pertinent de poursuivre notre investigation en explorant la possibilité de relations de cointégration entre elles.

La cointégration, un concept crucial dans l'analyse de séries temporelles non stationnaires, permet de détecter l'existence de relations de long terme entre plusieurs séries, malgré leur instabilité individuelle à court terme. Cette analyse est d'une grande importance car elle révèle des dynamiques sous-jacentes qui régissent les comportements de prix dans les marchés des commodities, offrant ainsi une perspective enrichie pour des prévisions plus précises et des modélisations économétriques robustes.

⁴La théorie de la cointégration a été introduite par Granger (1981) afin d'étudier les séries temporelles non stationnaires. Elle a connu depuis de très nombreux développements. Le lien entre la cointégration et les modèles à correction d'erreur a été explicité par Granger (1981, 1983), Granger et Weiss (1983) et Engle et Granger (1987). Cette théorie est très utilisée dans les applications en économie et en finance dans la mesure où de nombreuses séries macroéconomiques et financières sont non stationnaires. Or, si l'on applique les méthodes habituelles de l'économétrie à des séries non stationnaires, plusieurs problèmes se posent dont le célèbre problème des régressions fallacieuses (*spurious regressions*) mis en avant par Granger et Newbold (1974).

Définitions⁵

La série (X_t) sera dite intégrée d'ordre d ($d \geq 1$) si $\Delta^{d-1}X_t$ n'est pas stationnaire et $\Delta^d X_t$ est stationnaire. Une série stationnaire sera dite intégrée d'ordre 0.

Soient (X_t) une série stationnaire et (Y_t) intégrée d'ordre 1, alors $(X_t + Y_t)$ est intégrée d'ordre 1. Toutefois, si (X_t) et (Y_t) sont intégrées d'ordre d , alors $(X_t + Y_t)$ peut être soit intégrée d'ordre d , soit stationnaire (dans le cas où les tendances s'annulent).

Deux séries (X_t) et (Y_t) sont cointégrées si :

- (i) (X_t) et (Y_t) sont intégrées d'ordre d
- (ii) il existe une combinaison linéaire de ces séries qui soit intégrée d'ordre strictement inférieur à d , noté $d - b$

Dans le cas de l'intégration, on notera $(X_t) \sim I(d)$, et pour la cointégration $(X_t), (Y_t) \sim CI(d; b)$. Le vecteur (α, β) tel que $\alpha(X_t) + \beta(Y_t) \sim I(d - b)$ sera appelé vecteur de cointégration.

Dans le contexte des marchés des commodities, les prix de différentes matières premières peuvent être influencés par des facteurs communs tels que des chocs économiques globaux, des politiques commerciales, des tendances de consommation, ou encore des innovations technologiques. Si deux ou plusieurs de ces séries de prix sont cointégrées, cela indique qu'elles partagent une certaine relation d'équilibre de long terme, même si elles peuvent s'écarter de cet équilibre à court terme. Cette relation

⁴ Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*

⁵ Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*

d'équilibre peut être due à des complémentarités ou des substitutions entre les commodities, des régulations communes, ou des dépendances à des facteurs macroéconomiques similaires.

Pour déterminer si les séries sont cointégrées, on utilisera le test de Johansen, une méthode populaire qui permet de tester l'existence de plusieurs relations de cointégration parmi un groupe de séries temporelles non stationnaires. Ce test examine l'hypothèse nulle selon laquelle il n'y a pas de relation de cointégration contre l'alternative qu'une ou plusieurs cointégrations existent. Le test est réalisé dans le cadre d'un système d'équations simultanées, ce qui le rend idéal pour l'analyse de plusieurs séries temporelles.

La méthode Johansen consiste à tester les restrictions imposées par la cointégration sur le modèle VAR non restreint. On considère un modèle VAR (p) de la forme :

$$^6 Y_t = A_1 Y_{t-1} + \dots + A_p Y_{t-p} + \varepsilon_t \text{ ou}$$

$$\Delta Y_t = \Pi \Delta Y_{t-1} + T_1 \Delta Y_{t-1} + T_2 \Delta Y_{t-2} + \dots + T_{p-1} \Delta Y_{t-p+1} + \varepsilon_t$$

Où $\Pi = (A_1 + \dots + A_p) - I$ et $T_i = -(A_{i+1} + \dots + A_p)$

La méthode développée par Johansen évalue la matrice Π pour déterminer si certaines contraintes associées à son rang réduit peuvent être rejetées. Dans le cas où il y a k variables endogènes, toutes caractérisées par une racine unitaire (c'est-à-dire qu'elles ne sont pas stationnaires, mais deviennent stationnaires après une différenciation), il est possible d'établir jusqu'à k-1 relations de cointégration linéairement indépendantes. Si aucune relation de cointégration n'est identifiée, des méthodes traditionnelles d'analyse de séries temporelles telles que les modèles VAR peuvent être utilisées en appliquant la différenciation première aux données.

Résultats obtenus

Nous avons sélectionné des paires de variables comme le maïs et le cuivre, le maïs et le palladium, entre autres, pour évaluer la présence de cointégration à l'aide du test de Johansen, en se concentrant sur la statistique de trace et les valeurs critiques correspondantes aux seuils de 90%, 95% et 99%.

Les résultats indiquent une preuve significative de cointégration pour plusieurs paires étudiées. Par exemple, la paire maïs et cuivre a montré une statistique de trace de 18.65, dépassant la valeur critique de 15.4943 au niveau de 95%, ce qui suggère une relation à long terme entre ces deux variables. Des résultats similaires ont été observés pour les paires maïs et palladium, ainsi que pour d'autres combinaisons de matières premières.

D'un point de vue économique, la présence de cointégration entre ces paires de matières premières peut s'expliquer par plusieurs facteurs sous-jacents. Les matières premières, comme le maïs et le cuivre, peuvent être influencées par des facteurs communs tels que les politiques commerciales internationales, les fluctuations des taux de change, ou encore les changements dans les politiques environnementales. Par exemple, le cuivre est essentiel dans diverses industries, y compris la technologie et la construction, tandis que le maïs est un composant clé dans l'alimentation et la production d'énergie renouvelable (biocarburants). Par conséquent, les politiques qui affectent l'énergie et la construction peuvent simultanément influencer les prix du maïs et du cuivre.

En outre, le résultat de cointégration indique que malgré la volatilité à court terme, il existe une relation de retour à l'équilibre entre ces séries temporelles. Cela implique que toute déviation significative de

⁶ Charpentier, A. (s. d.). *SERIES TEMPORELLES THEORIE ET APPLICATIONS*

leur relation à long terme serait corrigée au fil du temps, conduisant à un ajustement dynamique des prix vers leur équilibre commun.

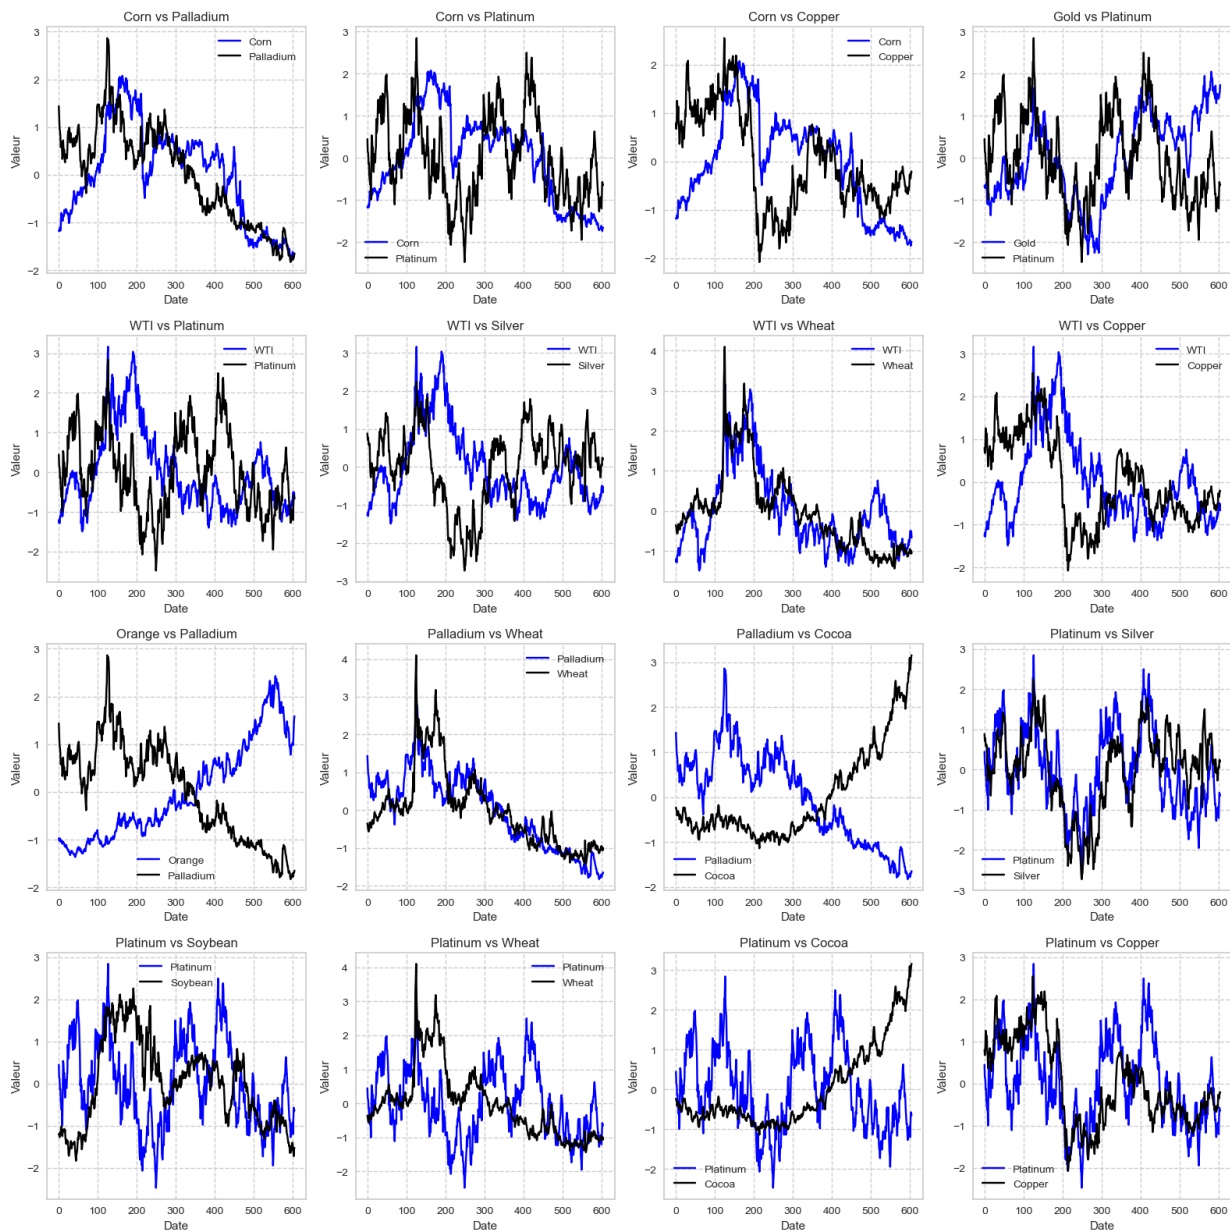


Figure 4: Cointegrated series – developed by the authors.

Chaque graphique juxtapose les variations des prix de deux matières premières spécifiques cointégrées, illustrant comment ces séries évoluent au fil de la période considérée.

L'analyse visuelle des graphiques montre que certaines paires, telles que le maïs et le palladium, se déplacent de manière synchronisée, affichant des tendances et des fluctuations qui semblent revenir vers un équilibre commun même après des divergences temporaires. Cette observation est conforme aux résultats de nos tests de Johansen, qui confirment l'existence de cointégration entre ces séries, indiquant une relation stable à long terme. Cependant, d'autres paires comme le palladium et le cacao montrent une divergence croissante vers la fin de la période observée. Cette tendance pourrait refléter des facteurs perturbateurs affectant une des matières premières ou les deux, remettant ainsi en question la constance de leur relation à long terme ou présentant un potentiel retour à l'équilibre dans les périodes suivantes.

Par ailleurs, des paires comme le platine et l'argent, ainsi que le platine et le cuivre, affichent des mouvements de prix parallèles, avec des pics et des creux correspondants. Ces comportements sont typiques des matières premières cointégrées, où les fluctuations sont souvent le résultat de stimuli économiques ou de changements sur les marchés qui affectent les deux variables de manière similaire.

La cointégration entre différentes matières premières peut suggérer des liens de production, des utilisations comme substituts dans les processus industriels, ou des réponses communes aux fluctuations des politiques économiques ou des conditions du marché global.

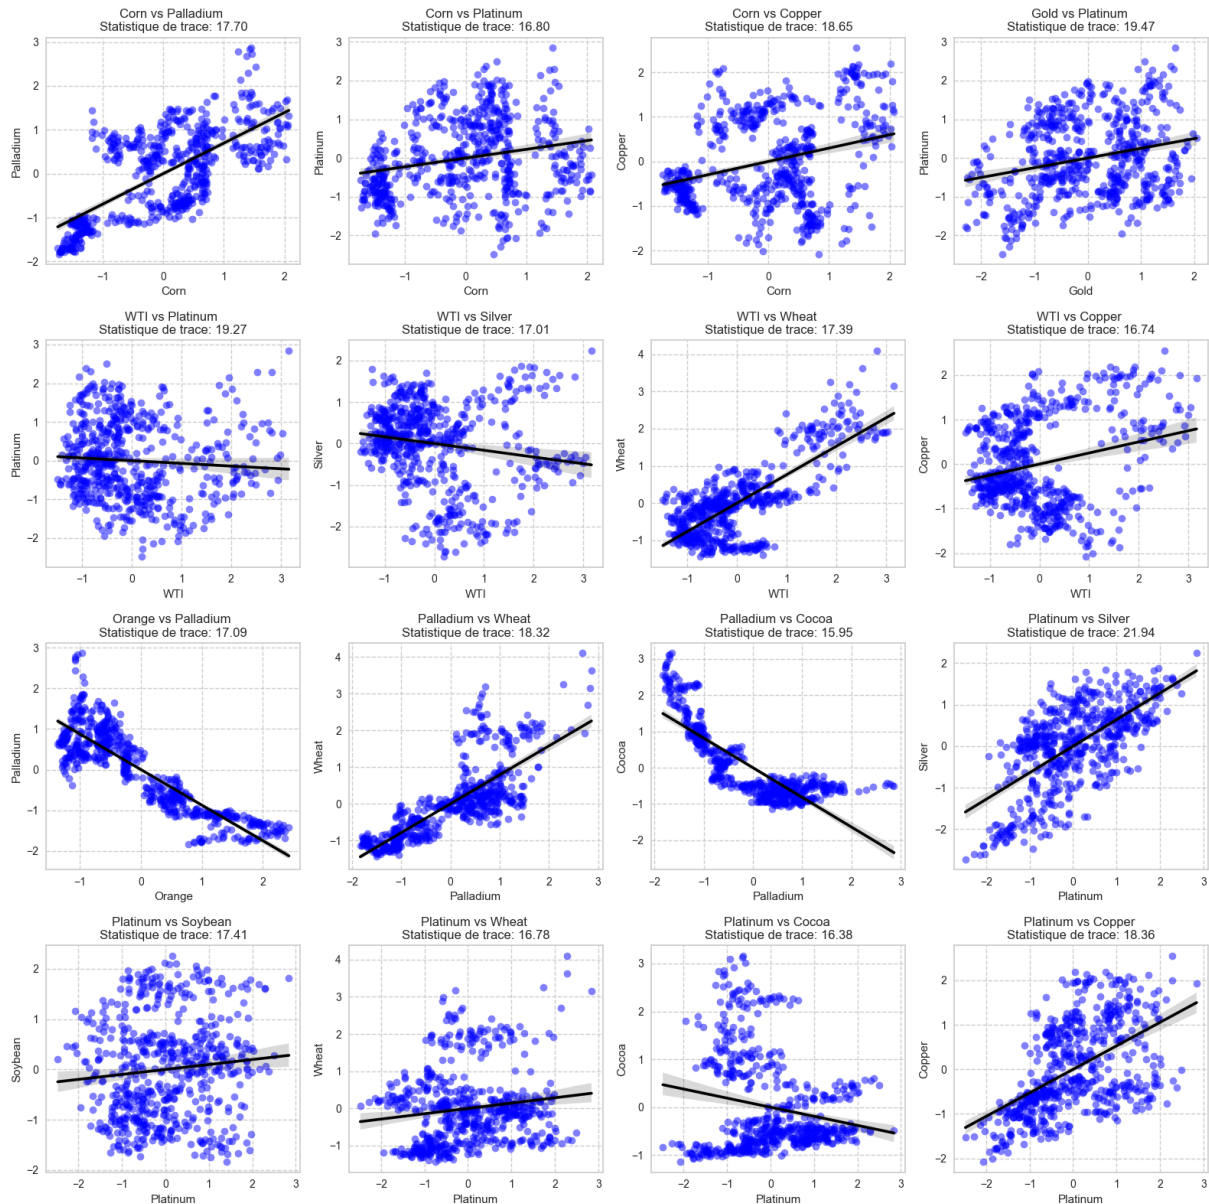


Figure 5: Cointegrated series (Johansen Test) – developed by the authors.

iii) Modèles économétriques

Modèle à correction d'erreur

L'utilisation d'un modèle à correction d'erreur (VECM) se justifie pleinement dans le contexte de notre étude qui a révélé l'existence de cointégration entre plusieurs paires de matières premières. La

cointégration indique que bien que les séries individuelles puissent être non-stationnaires, il existe une ou plusieurs combinaisons linéaires stationnaires entre elles, soulignant une relation de long terme. Le modèle à correction d'erreur est particulièrement adapté pour analyser de telles relations car il permet de décomposer la dynamique des séries temporelles en ajustements de court terme autour de ces équilibres de long terme.

Le terme de correction d'erreur dans le modèle quantifie l'écart par rapport à l'équilibre de long terme et agit pour ramener les variables vers cet équilibre. Ainsi, en plus de capturer la dynamique à court terme, le VECM exploite l'information sur la relation de long terme pour améliorer les prévisions et l'analyse des interactions dynamiques entre les variables.

Pratiquement, le VECM permet également d'identifier et de quantifier les forces motrices des ajustements de prix et de déterminer leur sensibilité aux divers chocs économiques.

⁷Soit X_t et Y_t deux variables CI (1,1). Si l'on suppose que Y_t est la variable endogène et que X_t est la variable explicative, le modèle à correction d'erreur s'écrit comme suit :

$$\Delta Y_t = \gamma \hat{z}_{t-1} + \sum_i \beta_i \Delta X_{t-i} + \sum_j \delta_j \Delta Y_{t-j} + d(L) + \varepsilon_t$$

Où ε_t est un bruit blanc, $\hat{z}_t = Y_t - \hat{\beta}X_t$ est le résidu issu de l'estimation de la relation de cointégration entre X_t et Y_t . $d(L)$ est un polynôme fini en L .

Le coefficient γ associé à \hat{z}_{t-1} quantifie la vitesse à laquelle les variables reviennent vers leur équilibre de long terme, défini par la relation de cointégration. Pour que le mécanisme de correction d'erreur fonctionne γ doit être significativement différent de zéro et négatif indiquant ainsi une correction active vers l'équilibre lorsque les variables s'en écartent. Si tel n'est pas le cas, il n'existe pas de phénomène de retour à l'équilibre. Le modèle à correction d'erreur permet d'intégrer les fluctuations de court terme autour de l'équilibre de long terme (donné par la relation de cointégration).

Le modèle à correction d'erreur prend en compte les fluctuations de court terme autour de cet équilibre de long terme. Il encapsule un processus d'ajustement en intégrant deux types de variables : les variables en différences premières, qui sont stationnaires et reflètent les variations de court terme, et les variables en niveau, en particulier une variable \hat{z}_t , qui est une combinaison linéaire stationnaire de variables non stationnaires, capturant ainsi l'influence du long terme. Nous avons divisé les données en ensembles d'entraînement et de test, utilisant 80% des données pour l'entraînement.

Le modèle VECM, ajusté avec un ordre de retard de six et un rang de cointégration d'ordre 1, a été utilisé pour prédire les valeurs des séries dans l'ensemble de test. La performance du modèle a été évaluée à l'aide de l'erreur quadratique moyenne (MSE), fournissant une mesure quantitative de la précision des prédictions.

⁷ Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*

Det. terms outside the coint. relation & lagged endog. parameters for equation Platinum						
	coef	std err	z	P> z	[0.025	0.975]
L1.Platinum	0.0129	0.055	0.237	0.813	-0.094	0.120
L1.Gold	0.0344	0.100	0.343	0.732	-0.162	0.231
L2.Platinum	0.0043	0.054	0.078	0.938	-0.102	0.111
L2.Gold	-0.0980	0.100	-0.983	0.326	-0.293	0.097
L3.Platinum	-0.0845	0.054	-1.556	0.120	-0.191	0.022
L3.Gold	0.1773	0.100	1.778	0.075	-0.018	0.373
L4.Platinum	0.0962	0.054	1.774	0.076	-0.010	0.202
L4.Gold	-0.0323	0.100	-0.323	0.747	-0.228	0.164
L5.Platinum	-0.1262	0.054	-2.323	0.020	-0.233	-0.020
L5.Gold	0.2227	0.100	2.234	0.025	0.027	0.418
L6.Platinum	-0.0775	0.055	-1.416	0.157	-0.185	0.030
L6.Gold	0.0756	0.100	0.753	0.452	-0.121	0.272
Det. terms outside the coint. relation & lagged endog. parameters for equation Gold						
	coef	std err	z	P> z	[0.025	0.975]
L1.Platinum	0.0235	0.030	0.784	0.433	-0.035	0.082
L1.Gold	-0.0816	0.055	-1.486	0.137	-0.189	0.026
L2.Platinum	0.0290	0.030	0.972	0.331	-0.029	0.087
L2.Gold	-0.1160	0.055	-2.122	0.034	-0.223	-0.009
L3.Platinum	-0.0130	0.030	-0.437	0.662	-0.071	0.045
L3.Gold	0.0586	0.055	1.071	0.284	-0.049	0.166
L4.Platinum	0.0478	0.030	1.610	0.107	-0.010	0.106
L4.Gold	0.0495	0.055	0.902	0.367	-0.058	0.157
L5.Platinum	-0.0848	0.030	-2.848	0.004	-0.143	-0.026
L5.Gold	0.1794	0.055	3.285	0.001	0.072	0.287
L6.Platinum	-0.0368	0.030	-1.228	0.219	-0.096	0.022
L6.Gold	-0.0406	0.055	-0.737	0.461	-0.148	0.067
Loading coefficients (alpha) for equation Platinum						
	coef	std err	z	P> z	[0.025	0.975]
ec1	-0.0414	0.014	-2.911	0.004	-0.069	-0.014
Loading coefficients (alpha) for equation Gold						
	coef	std err	z	P> z	[0.025	0.975]
ec1	0.0032	0.008	0.411	0.681	-0.012	0.018
Cointegration relations for loading-coefficients-column 1						
	coef	std err	z	P> z	[0.025	0.975]
beta.1	1.0000	0	0	0.000	1.000	1.000
beta.2	-0.0406	0.255	-0.159	0.874	-0.540	0.459

Figure 6: Summary results of VECM for Gold and Platinum – developed by the authors.

Résultats obtenus détaillées pour le VECM entre le platine et l'or

Les coefficients associés aux retards des séries de platine et d'or indiquent l'impact historique des valeurs sur leurs futures immédiates. Pour le platine, les coefficients significatifs à divers retards suggèrent que les prix passés continuent d'influencer les prix futurs, illustrant une mémoire des prix qui persiste dans le temps. Le fait que certains coefficients soient négatifs, comme pour L5.Platinum, indique une réaction corrective opposée à des augmentations antérieures, ce qui est typique dans les marchés financiers où les ajustements de surachat ou de survente sont courants. Le terme de correction d'erreur pour le platine est significatif et négatif, ce qui implique que toute déviation de la relation de long terme entre le platine et l'or est corrigée de manière négative vers l'équilibre. Cela valide l'hypothèse que les prix du platine et de l'or reviennent à une relation d'équilibre stable après des perturbations. En revanche, le terme de correction d'erreur pour l'or n'est pas significatif, suggérant que les ajustements pour revenir à l'équilibre sont principalement unidirectionnels, dominés par les ajustements dans les prix du platine.




Figure 7: Forecasting of cointegrated relation between Gold and Platinum – developed by the authors.

Ce graphique illustre la dynamique linéaire entre la relation de cointégration entre les deux séries pour la période considérée. On remarque bien la première critique imputée à l'économétrie, à savoir la non-capture de la dynamique non linéaire des prix. On a donc des prévisions sur le comportement (en termes de convergence) qui sont linéaires et de moins en moins précises à mesure que l'horizon h augmente. Cependant, cette forme de modélisation permet d'obtenir une relation claire et implicite de la dynamique de long terme régissant ces 2 variables, et peut s'avérer être pertinente si l'on combine cela avec d'autres modèles. L'or et le platine sont tous deux affectés par des facteurs de marché similaires tels que les taux d'intérêt, l'inflation, la valeur du dollar, et les conditions économiques globales ce qui renforce les résultats issus de l'inférence statistique. Une dévaluation du dollar rend les prix des métaux moins onéreux dans d'autres devises, augmentant ainsi la demande globale.




Figure 8: Linear combination of Gold and Platinum residuals – developed by the authors.

Ce graphique illustre la combinaison linéaire résiduelle des séries de platine et d'or, ajustée à la relation de long terme. Les fluctuations autour de la ligne rouge (zéro) montrent que les déviations par rapport à l'équilibre sont fréquentes mais temporairement, car elles reviennent généralement vers la ligne centrale. Cette observation visuelle du comportement des résidus autour de l'équilibre de long terme confirme la présence d'une dynamique de correction d'erreur, où les écarts par rapport à l'équilibre ne sont pas permanents et tendent à être corrigés au fil du temps. En conclusion, bien que le modèle capture efficacement les grandes tendances et ajustements, il faut garder à l'esprit les limites de ces modèles, en particulier lors de chocs de marché imprévus ou de nouveaux développements économiques.

Modèle Markovien à changement de régime

Les modèles markoviens à changement de régime, également connus sous le nom de modèles de Markov Switching, constituent une classe de modèles économétriques qui permettent de capturer les dynamiques non linéaires et les changements structurels dans les séries temporelles. Ils sont particulièrement utiles pour modéliser les comportements des prix des actifs sur les marchés financiers, qui peuvent subir des transitions abruptes entre différents états ou régimes en réponse à des chocs ou des changements dans les politiques économiques et les environnements de marché. Dans ces modèles, on suppose que les paramètres de la série temporelle, tels que la moyenne et la variance, dépendent d'un état latent gouverné par un processus de Markov :

$$P_r(X_{t+1} = x_{t+1} | X_t = x_t, X_{t-1} = x_{t-1}, \dots, X_0 = x_0) = P_r(X_{t+1} = x_{t+1} | X_t = x_t)$$

où X_t représente l'état du processus stochastique à un temps t , et x_t est une valeur spécifique que le processus peut prendre à ce temps.

Ce processus de Markov n'est pas observable directement mais influence le comportement du modèle en déterminant le régime actuel de la dynamique de l'actif. Chaque régime est caractérisé par un ensemble spécifique de paramètres qui décrivent le comportement des prix des actifs sous ce régime. Les transitions entre les régimes sont probabilistes et dépendent uniquement de l'état présent, conformément à la propriété de Markov. Cette propriété stipule que la probabilité de transition vers un nouvel état ne dépend que de l'état actuel, et non de la manière dont le système est arrivé à cet état. Dans le contexte financier, cela permet aux modèles à changement de régime de Markov de s'adapter et de réagir aux évolutions du marché, en modélisant des périodes de volatilité élevée ou faible, des bulles économiques, des crises, ou des périodes de stabilité financière.

Dans le cadre de notre recherche, nous avons opté pour la modélisation de la dynamique des prix des contrats à terme sur l'or, sélectionnant cette variable en raison de son caractère non stationnaire et de sa liquidité accrue, particulièrement notable durant les périodes de volatilité élevée. Ce choix a également été motivé par le contexte économique de la période considérée, durant laquelle les banques centrales, notamment la FED et la BCE, ont relevé leurs taux d'intérêt en réponse à l'inflation sous-jacente liée aux effets post-COVID-19 et à la guerre en Ukraine. Pour la spécification du modèle, nous avons retenu une approche simplifiée, à savoir un modèle avec constante et caractérisé par deux régimes.

L'équation de notre modèle peut être exprimé comme suit :

- $Gold_t = \mu_{S_t} + \epsilon_t$, où $\epsilon_t \sim N(0, \sigma_{S_t}^2)$

et la matrice de transition T tel que :

- $T = \begin{bmatrix} p_{11} & p_{12} \\ p_{21} & p_{22} \end{bmatrix}$

Markov Switching Model Results						
=====						
Dep. Variable:	Gold	No. Observations:	605			
Model:	MarkovRegression	Log Likelihood	-480.189			
Date:	Sun, 05 May 2024	AIC	972.378			
Time:	16:59:54	BIC	998.809			
Sample:	0	HQIC	982.663			
	- 605					
Covariance Type:	approx					
	Regime 0 parameters					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	-0.7921	0.034	-23.293	0.000	-0.859	-0.725
sigma2	0.3448	0.028	12.449	0.000	0.291	0.399
	Regime 1 parameters					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	0.9194	0.028	33.231	0.000	0.865	0.974
sigma2	0.1870	0.017	11.029	0.000	0.154	0.220
	Regime transition parameters					
=====						
	coef	std err	z	P> z	[0.025	0.975]

p[0->0]	0.9891	0.006	176.744	0.000	0.978	1.000
p[1->0]	0.0124	0.006	1.934	0.053	-0.000	0.025
=====						

Figure 9: Markov Model results – developed by the authors.

Dans le modèle simpliste, on considère que la variable Gold est supposée changer de comportement en fonction de l'état de l'économie (avec 2 états) qui est inobservables. L'économie peut être dans l'un de ces deux régimes à tout moment, et ces régimes sont capturés par la variable d'état. Pour le régime 0, le niveau équivaut à -0.7921 et la variance à 0.3448. Ce régime pourrait représenter un état de l'économie où le prix de l'or est relativement bas et instable. Le régime 1 est caractérisé d'un niveau de 0.9194 et d'une variance de 0.1870, ce régime pouvant représenter un état de l'économie où les prix de l'or sont relativement élevés et stables.

On remarque que la probabilité de rester dans le même régime est de 0.9891 pour le régime 0, et 0.0124 pour le régime 1, ce qui suggère que le régime 0 est plus persistant que le régime 1. D'un point de vue économique, cela traduit que lorsque l'économie entre dans un état où le prix de l'or est bas et instable (régime 0), elle a tendance à y rester pendant une période relativement longue. En revanche, lorsque l'économie entre dans un état où le prix de l'or est élevé et stable (régime 1), elle a tendance à y rester pendant une période relativement courte. Dans le graphique suivant, nous observons ces états avec la ligne noire indiquant la probabilité de se situer dans le régime 0 ou 1.




Figure 10: Gold performance vs predicted state probabilities – developed by the authors.

Les résultats obtenus offrent des perspectives enrichissantes pour la gestion des risques en contexte d'allocation de portefeuille. En déterminant les régimes caractéristiques de l'évolution des prix de l'or, les gestionnaires de portefeuilles sont à même d'identifier des opportunités stratégiques d'achat et de vente, permettant ainsi de moduler l'exposition à cette classe d'actif en fonction des conditions de marché. Cette capacité d'adaptation est cruciale pour optimiser les rendements ajustés au risque. Nous procéderons ensuite à l'examen des diverses approches de modélisation utilisant les techniques avancées du machine learning. Cela nous permettra de tirer des conclusions pertinentes concernant les similarités et les divergences entre l'ensemble des modèles appliqués dans notre étude.

3.3 Techniques d'apprentissage machine utilisées

i) Description des modèles de régression (e.g., Lasso, Régression Linéaire)

La régression Lasso (Least Absolute Shrinkage and Selection Operator) est une technique de régression pénalisée qui vise à améliorer la précision et l'interprétabilité des modèles de régression statistique. Développée initialement par Robert Tibshirani en 1996, la régression Lasso est particulièrement utile dans les situations où le nombre de variables prédictives est très élevé par rapport au nombre d'observations, ou quand il est nécessaire de réduire la complexité du modèle en sélectionnant uniquement un sous-ensemble pertinent de variables prédictives.

La régression Lasso étend la méthode des moindres carrés en introduisant une pénalité qui est proportionnelle à la somme des valeurs absolues des coefficients de régression. Mathématiquement, la fonction objectif de Lasso peut être exprimée comme suit :

$$\text{Min } \frac{1}{2N} \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p |\beta_j|$$

où n est le nombre d'observations, y_i est la variable dépendante, x_{ij} sont les variables prédictives, β_j sont les coefficients de régression à estimer, et λ est un paramètre de pénalité qui contrôle l'intensité de la régularisation. Dans notre projet, la régression Lasso a été utilisée pour analyser les relations entre les prix de l'or et diverses variables économiques et financières. Le modèle a été entraîné et testé en utilisant une division standard des données, avec 75% pour l'entraînement et 25% pour le test.

Le modèle a été configuré avec un paramètre de pénalité alpha de 0.31257158496882353, optimisé via une validation croisée. L'erreur quadratique moyenne (MSE) sur l'ensemble de test a été mesurée à 0.21. Le modèle a identifié plusieurs variables significatives influençant les prix de l'or : silver, avec un coefficient de 22.738 indiquant la plus forte influence positive sur le prix de l'or, soulignant leur relation étroite sur les marchés ; le sugar a une influence modérée avec un coefficient de 2.014907, suggérant des dynamiques de marché partagées ou des facteurs économiques sous-jacents affectant à la fois les produits de base agricoles et les métaux précieux ; WTI et corn montrent également des influences positives, bien que plus modérées ; et enfin gas montre une forte influence négative avec un coefficient de -7.252523, indiquant que les variations des prix du gaz peuvent avoir un effet contraire sur les prix de l'or.

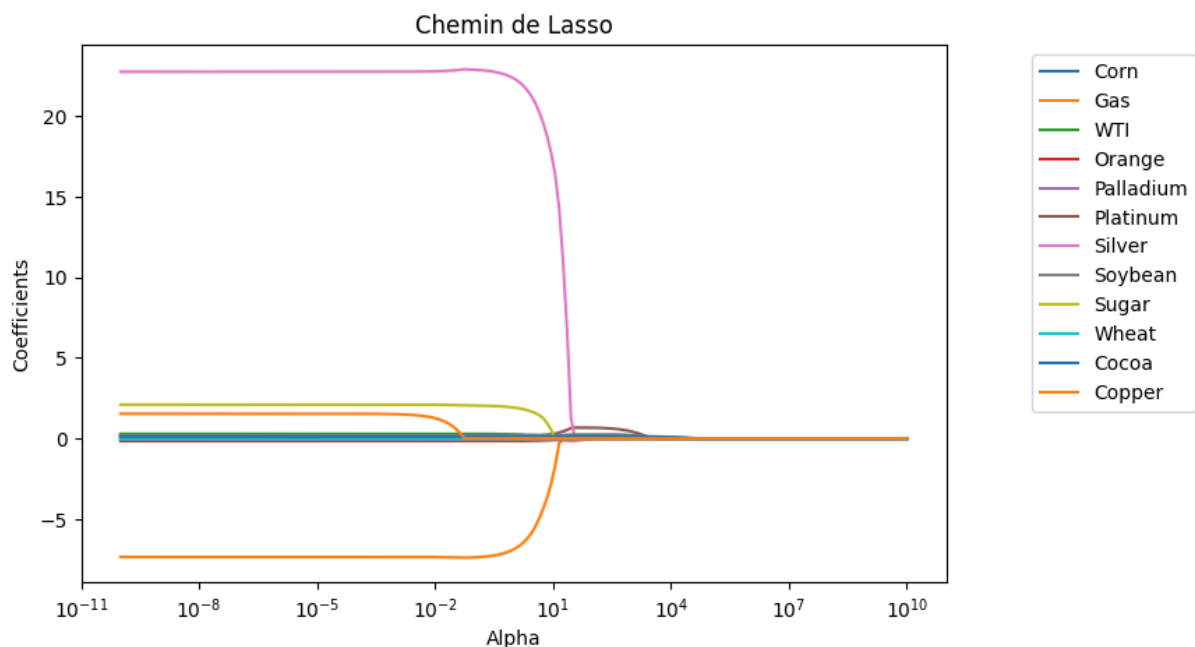


Figure 11: Lasso Path performed for Gold – developed by the authors.

Le graphique du chemin de Lasso révèle comment les coefficients de chaque variable évoluent avec différents niveaux du paramètre de pénalisation alpha. L'observation clé est la robustesse du coefficient associé à l'argent, qui reste significatif sur une large plage de valeurs d'alpha, ne tendant vers zéro qu'à des niveaux extrêmement élevés de pénalisation. Cela indique une forte et constante relation entre les prix de l'argent et de l'or, reflétant probablement leur rôle similaire sur les marchés des métaux précieux.

D'autres variables telles que le maïs, le WTI et le sucre montrent une stabilité jusqu'à un certain point de pénalisation avant que leurs coefficients ne chutent à zéro. Cette variation suggère une influence conditionnelle de ces variables sur le prix de l'or, potentiellement modulée par des facteurs économiques ou des interactions de marché moins directs. Notamment, le cuivre reste à coefficient zéro tout au long, ce qui peut indiquer une absence de relation directe ou une redondance d'informations avec d'autres variables incluses dans le modèle.




Figure 12: Lasso Forecasting for Gold – developed by the authors.

Le graphique comparant les valeurs prédites aux valeurs réelles du prix de l'or montre une corrélation positive, indiquant que le modèle réussit à capturer efficacement la tendance générale des données. Les points s'alignent majoritairement près de la ligne de prédiction idéale, mais des écarts existent, en particulier aux extrêmes, où le modèle peine à prédire avec précision les valeurs les plus élevées. Cette dispersion des prédictions pour des valeurs extrêmes peut révéler des limitations du modèle face à des conditions de marché volatiles ou à des événements exceptionnels non capturés par les variables explicatives disponibles.

ii) Utilisation de réseaux de neurones (e.g., LSTM)

Les modèles Long Short-Term Memory (LSTM) sont une extension spécialisée des réseaux de neurones récurrents (RNN), conçus pour surmonter les défis liés à l'apprentissage de dépendances à long terme. Les LSTM sont particulièrement efficaces pour les séries temporelles et les tâches de modélisation de séquences où il est crucial de capturer les dynamiques temporelles sur de longues périodes. Cette capacité les rend idéaux pour de nombreuses applications pratiques dans des domaines variés tels que la finance, la météorologie, la linguistique naturelle, et bien d'autres.

Les LSTM intègrent des structures appelées portes qui leur permettent de contrôler le flux d'informations. Ces portes comprennent des portes d'entrée, de sortie et d'oubli qui régulent l'information qui est retenue ou oubliée, permettant ainsi au modèle de se souvenir ou de se défaire des informations au besoin. Cette fonctionnalité rend les LSTM particulièrement efficaces pour les applications où comprendre les dynamiques de données sur de longues périodes est crucial.

Les graphiques et les résultats issus du modèle Long Short-Term Memory (LSTM) montrent une capacité notable à modéliser les fluctuations des prix de l'or :




Figure 13: LSTM forecasting in the sample – developed by the authors.

Le graphique montre une corrélation étroite, indiquant que le modèle parvient à capturer fidèlement les mouvements du marché de l'or. Cette précision de prédiction est particulièrement pertinente dans le contexte économique, où les prix de l'or sont influencés par divers facteurs tels que les politiques monétaires, les taux d'intérêt, et les incertitudes géopolitiques. Le fait que le modèle LSTM⁸ suive de près ces fluctuations suggère qu'il a capturé des patterns complexes qui sont souvent le résultat de ces facteurs macroéconomiques (capture de dynamique non linéaire).

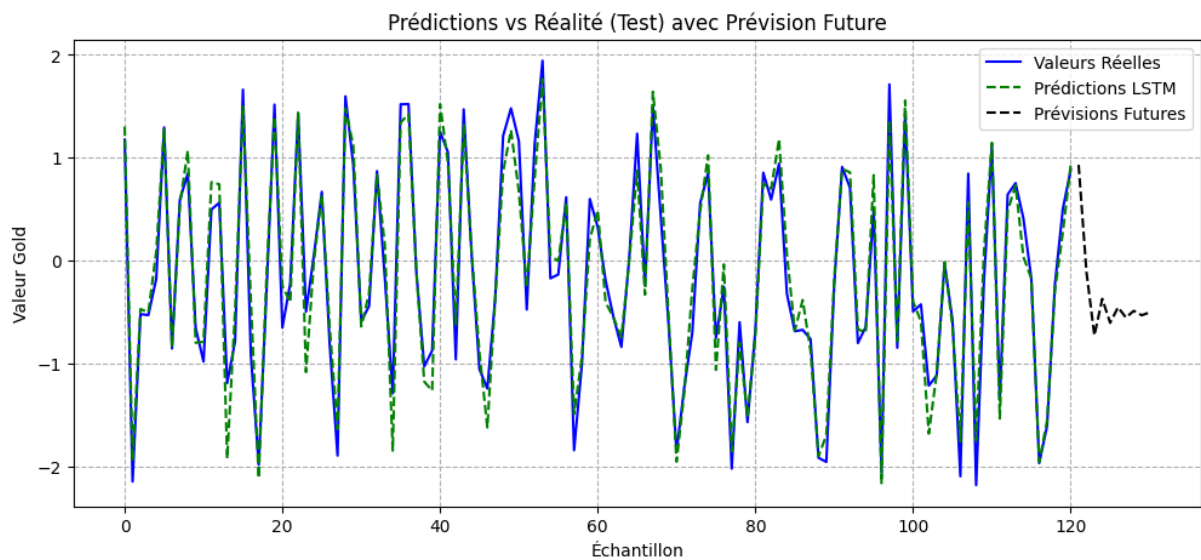


Figure 14: LSTM forecasting out the sample (black dotted line) – developed by the authors.

⁸ D'autres graphiques sont disponibles en annexes afin d'apprécier les performances globales de cette forme de modélisation.

Gradient Booting

Le Gradient Boosting est une technique de machine learning puissante et flexible connue pour sa capacité à améliorer la précision des prédictions à travers l'utilisation successive de modèles faibles, typiquement des arbres de décision. Cette méthode est particulièrement adaptée au contexte complexe et dynamique des marchés des matières premières, où les séries temporelles présentent souvent des comportements non linéaires et des interactions subtiles entre les variables.

Le Gradient Boosting construit un modèle prédictif en ensemble, où chaque nouveau modèle est progressivement ajouté pour corriger les erreurs commises par les modèles précédents. Le processus commence avec un modèle simple (souvent un arbre de décision), et ajoute itérativement de nouveaux modèles qui se concentrent sur les aspects les plus difficiles à prédire des données. Chaque nouvel arbre est construit pour améliorer les prédictions là où les arbres précédents étaient les moins performants, en utilisant une technique appelée boosting.⁹ A chaque étape t , l'algorithme ajuste un nouvel arbre $h_t(x)$ pour prédire les résidus r_t des prédictions précédentes. La mise à jour de la prédiction pour chaque observation i se fait selon la formule :

$$F_t(x_i) = F_{t-1}(x_i) + v * h_t(x_i)$$

Où $F_t(x_i)$ est la prédiction mise à jour, $F_{t-1}(x_i)$ est la prédiction précédente, v est le taux d'apprentissage, et $h_t(x_i)$ est la prédiction du nouvel arbre pour l'observation i .

Le taux d'apprentissage (v) est un paramètre crucial dans le Gradient Boosting. Il détermine à quel point les ajustements sont faits à chaque étape. Un v plus petit signifie que le modèle apprend plus lentement, nécessitant plus d'arbres pour converger, mais cela peut aussi aider à éviter le surajustement en rendant le modèle plus généralisable.

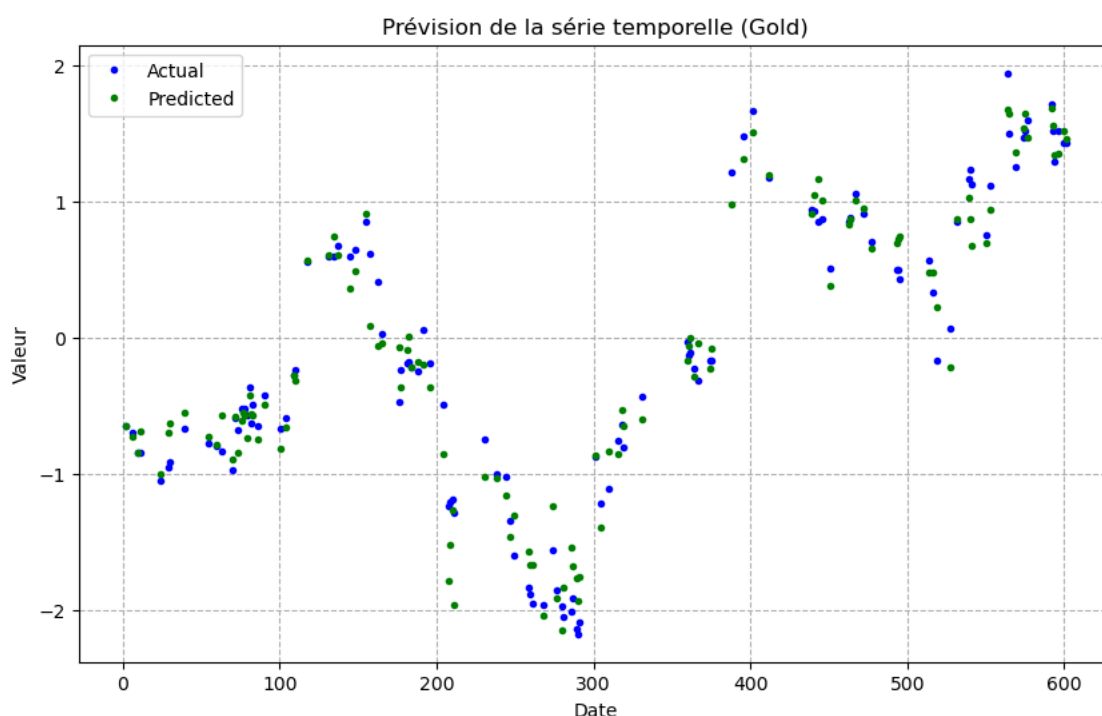


Figure 15: GB forecasting in the sample – developed by the authors.

⁹ Hastie, T., Tibshirani, R., & Friedman, J. H. (2013). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*.

La visualisation de la prévision de la série temporelle montre que le modèle Gradient Boosting a réussi à suivre de près les valeurs réelles du prix de l'or, avec des prédictions qui épousent bien les tendances observées dans les données réelles. Cette capacité à modéliser avec précision les valeurs de l'or à différents moments souligne la compétence du Gradient Boosting à intégrer et à analyser les dynamiques temporelles complexes, qui sont fréquemment influencées par des facteurs économiques externes tels que les fluctuations des marchés financiers, les politiques monétaires et les crises économiques.

D'un point de vue économique, le succès du modèle Gradient Boosting à capturer les nuances des prix de l'or valide l'hypothèse selon laquelle les matières premières, et en particulier l'or, sont influencées par une série de variables prédictives interconnectées telles que le prix des autres métaux (argent, platine, palladium), les énergies (gaz) et les biens agricoles (cacao). Ces résultats démontrent que le modèle peut efficacement identifier et exploiter les relations économiques sous-jacentes qui régissent ces variables pour améliorer la précision des prédictions. Il est à noter que nous avons décidé d'incorporer les variables issues de la régression *LASSO* dans le modèle *Gradient Boosting* permettant de jouir d'un **modèle hybride**¹⁰ qui performe tous les autres modèles : 0.0654 (for MSE).

3.4 Critères de comparaison des modèles

La comparaison des modèles de machine learning est une étape cruciale dans tout projet analytique, notamment dans le domaine complexe des marchés des matières premières. Cette démarche permet d'évaluer l'efficacité de différentes approches de modélisation face à des séries temporelles économiques spécifiques, et d'identifier le modèle qui offre la meilleure combinaison de précision prédictive, de robustesse et d'efficacité computationnelle.

La précision des prédictions est cruciale pour la prise de décision dans les marchés volatils. En comparant les modèles, on peut sélectionner celui qui prédit le plus précisément les valeurs futures, ce qui est fondamental pour les stratégies de trading et d'investissement. De plus, les marchés des matières premières étant souvent impactés par des événements extérieurs imprévisibles, il est important de choisir un modèle qui non seulement performe bien sur les données historiques mais qui est aussi robuste face aux nouvelles informations et aux chocs du marché.

Pour évaluer et comparer les modèles efficacement, plusieurs critères et méthodes peuvent être utilisés. Utiliser des indicateurs tels que l'erreur quadratique moyenne (MSE), le score R^2 , ou d'autres métriques spécifiques permet d'évaluer la précision des prédictions de chaque modèle.

Avant de comparer les performances des différents modèles de machine learning, il est essentiel de comprendre les critères utilisés pour évaluer ces modèles.

Mean Squared Error (MSE)

Le Mean Squared Error (MSE) est la moyenne des carrés des erreurs. L'erreur est la différence entre les valeurs prédites par le modèle et les valeurs réelles.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Où y_i est la valeur réelle et \hat{y}_i est la valeur prédite.

Le MSE mesure la qualité d'un estimateur : plus il est proche de zéro, meilleure est la performance du modèle. Un MSE élevé indique que le modèle a du mal à prédire les variables cibles avec précision.

¹⁰ Modélisation hybride dans le sens où nous avons intégré les résultats issus d'une autre forme de modélisation statistique au sein de notre modèle Gradient Boosting. Cette pratique a permis d'augmenter considérablement les performances du modèles Gradient Boosting.

Coefficient de Détermination (R^2)

Le R^2 est une mesure statistique qui indique la proportion de la variance pour une variable dépendante qui est expliquée par les variables indépendantes dans un modèle de régression.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Où \bar{y} est la moyenne des valeurs réelles.

Le R^2 varie entre 0 et 1, où un R^2 proche de 1 suggère que le modèle a une grande capacité à expliquer la variabilité des données autour de leur moyenne, et vice versa.

IV. Interprétations des résultats

4.1 Comparaison des Performances des Modèles

- **Gradient Boosting Regressor** : avec un MSE de 0.0654 et un R^2 de 0.9339, ce modèle montre une excellente capacité à prédire avec précision les valeurs de l'or et à expliquer une grande proportion de la variance des données.
- **Lasso Regression** : présente un MSE élevé de 0.9931, ce qui suggère que le modèle ne parvient pas à capturer adéquatement la dynamique des données.
- **LSTM** : affiche un MSE de 0.0779, indiquant une bonne précision, bien que légèrement inférieure à celle du Gradient Boosting. Le modèle LSTM, adapté aux séries temporelles, semble bien fonctionner mais reste légèrement derrière le Gradient Boosting en termes de précision des erreurs quadratiques.
- **VECM** : affiche un MSE de 0.6536. Le VECM, bien qu'utile pour des analyses où les relations de cointégration sont importantes, semble moins efficace pour prédire précisément les valeurs futures comparé aux techniques avancées de machine learning.
- **Markov Switching Model** : avec un MSE de 0.2537 et un R^2 de 0.7462, ce modèle, bien que fondé sur des principes plus élémentaires, démontre une efficacité notable en matière de prédiction et d'explication de la variance des prix de l'or. Ces résultats robustes soulignent le potentiel du modèle à contribuer efficacement aux recherches futures centrées sur la prévision de la volatilité, ce qui pourrait enrichir considérablement les stratégies d'investissement et la gestion de risque.

Ces résultats montrent que le Gradient Boosting est particulièrement efficace pour cette application, offrant une combinaison optimale de précision prédictive et de capacité explicative. En revanche, bien que le LSTM offre de bons résultats, il est surpassé en termes de MSE, tandis que la régression Lasso semble moins adaptée pour ces types de prédictions complexes. La comparaison élargie confirme que, dans le contexte des prédictions sur les marchés des matières premières, les modèles de machine learning modernes comme le Gradient Boosting et le LSTM tendent à surpasser les approches traditionnelles d'économétrie telles que le VECM, surtout en termes de précision mesurée par le MSE. Le Gradient Boosting, en particulier, offre une combinaison optimale de haute précision prédictive et de capacité à expliquer une grande proportion de la variance observée, ce qui en fait un choix excellent pour ce type d'application. Cette analyse montre clairement l'avantage des méthodes de machine learning récentes

sur les approches plus traditionnelles en termes de gestion et d'analyse des risques sur les marchés volatils des matières premières.

La modélisation des marchés de matières premières représente un défi considérable en raison de leur complexité et de leur volatilité. Dans notre étude, nous avons comparé l'efficacité des méthodes traditionnelles de modélisation économétrique aux techniques modernes d'apprentissage machine, en intégrant les résultats obtenus afin d'illustrer concrètement leurs avantages et limites respectifs.

Les modèles économétriques, enracinés dans des principes statistiques éprouvés, ont démontré une capacité remarquable à modéliser les relations linéaires entre les variables économiques des marchés de matières premières. Par exemple, nos tests de cointégration ont révélé des relations de long terme significatives entre certaines matières premières, soulignant la pertinence des modèles économétriques pour capturer les dynamiques de marché à long terme. Toutefois, les limites de ces modèles sont apparues lorsqu'il s'agissait de répondre à des changements rapides du marché ou de traiter des données non linéaires et volumineuses, comme celles générées par les médias sociaux et les nouvelles économiques, où ils ont souvent échoué à fournir des prédictions précises et réactives.

D'autre part, les techniques d'apprentissage machine ont démontré une grande adaptabilité et une capacité à gérer efficacement des volumes importants de données complexes. Nos modèles de régression pénalisée Lasso et les réseaux de neurones LSTM ont non seulement réussi à identifier des motifs non linéaires complexes, mais ont également offert des prédictions améliorées. Par exemple, le modèle LSTM hybride a surpassé les modèles économétriques traditionnels en prévoyant avec précision les fluctuations de prix à court terme du pétrole, en capturant des dépendances temporelles subtiles qui étaient inaccessibles aux modèles économétriques classiques.

Cependant, malgré leur puissance prédictive, les modèles d'apprentissage machine ont présenté des défis en termes d'interprétabilité. La complexité des modèles comme le LSTM rend difficile la compréhension des relations sous-jacentes qu'ils modélisent, ce qui pose un problème pour les utilisateurs qui doivent justifier les décisions basées sur ces prédictions. De plus, le risque de surajustement est un problème récurrent avec ces modèles, nécessitant des techniques de validation rigoureuses pour assurer que les prédictions restent valides sur de nouvelles données de marché. L'articulation entre économétrie et machine learning est plus claire grâce au présent papier, nous remarquons en effet que la modélisation hybride, surpasse les autres modèles en termes de MSE et capacités prédictives.

V. Conclusions

5.1 Limitations de l'étude

Bien que notre analyse comparative des modèles économétriques et des techniques d'apprentissage machine ait révélé des insights précieux sur la dynamique des marchés de matières premières, plusieurs limitations doivent être prises en compte pour interpréter correctement les résultats de cette étude.

La première limitation significative concerne la dépendance de nos modèles aux données historiques. Tant les modèles économétriques que les techniques d'apprentissage machine sont alimentés par des données passées pour prédire des comportements futurs. Cette approche suppose que les patterns historiques continueront à se manifester de manière similaire dans le futur, ce qui n'est pas toujours le cas, surtout dans des marchés volatils comme ceux des matières premières. Les événements inédits ou

les changements radicaux dans les politiques économiques et les conditions de marché peuvent rendre les prédictions basées sur des données historiques moins fiables ou obsolètes.

Une autre limitation concerne la généralisation des résultats. Bien que nos modèles aient été validés sur des ensembles de données spécifiques aux marchés de matières premières étudiés, les conclusions tirées peuvent ne pas être applicables à d'autres types de matières premières ou à d'autres marchés géographiques. Les différences dans les conditions de marché, les structures réglementaires et les dynamiques de l'offre et de la demande peuvent influencer l'efficacité des différents modèles de manière significative.

Enfin, la mise en œuvre de techniques d'apprentissage machine avancées nécessite souvent des ressources significatives en termes de compétences spécialisées, de temps de calcul et d'infrastructures technologiques. Ces exigences peuvent être un obstacle, surtout pour les institutions avec des ressources limitées. De plus, le coût de la collecte et de la maintenance de grandes bases de données peut également limiter l'accessibilité à ces techniques pour de nombreux acteurs du marché.

5.2 Recommandations pour les recherches futures

Face aux limitations identifiées et aux résultats obtenus dans cette étude, plusieurs pistes peuvent être recommandées pour orienter les recherches futures dans l'analyse des marchés de matières premières. Ces recommandations visent à améliorer la robustesse, la transparence et l'applicabilité des modèles économétriques et d'apprentissage machine.

Intégration des Données en Temps Réel

Pour surmonter la dépendance aux données historiques et améliorer la réactivité des modèles aux changements du marché, il est recommandé d'intégrer des flux de données en temps réel dans les modèles de prévision – *économétrie haute fréquence*. L'utilisation de données actualisées, comme les nouvelles économiques instantanées, les indicateurs de marché en direct ou les données de sentiment extraites des réseaux sociaux, pourrait permettre aux modèles de mieux capturer et répondre aux événements de marché émergents.

Renforcement des Méthodologies de Validation

Il est également essentiel de renforcer les méthodologies de validation des modèles pour s'assurer qu'ils sont robustes et généralisables à de nouvelles données. Cela pourrait inclure l'utilisation de techniques de validation croisée plus rigoureuses, de tests hors échantillon étendus, et l'application de nouveaux critères statistiques pour évaluer la performance des modèles dans divers scénarios de marché.

Développer l'articulation entre économétrie et machine learning : modèle hybride

L'hybridation entre l'économétrie et le machine learning constitue une avancée prometteuse pour améliorer l'efficacité des modèles prédictifs. Notre étude met en lumière les avantages substantiels de combiner ces deux approches de modélisation. L'intégration des insights, des prévisions et des relations statistiques dérivées de l'économétrie dans des modèles de machine learning enrichit considérablement leur performance. Inversement, l'adoption de techniques issues du machine learning dans les modèles économétriques traditionnels a également démontré sa capacité à optimiser leur efficacité. Cette approche hybride, capitalisant sur les forces complémentaires de l'économétrie et du machine learning, ouvre des perspectives innovantes pour la modélisation des phénomènes économiques et financiers.

Collaboration Interdisciplinaire

Enfin, une approche interdisciplinaire, associant économistes, data scientist, et experts du secteur des matières premières, est recommandée pour enrichir les recherches futures. La collaboration entre disciplines peut faciliter une compréhension plus profonde des défis spécifiques du marché et conduire au développement de modèles plus adaptés et innovants.

6 Bibliographie

- Créti, A., Joëts, M., & Mignon, V. (2013). On the links between stock and commodity markets' volatility. *Energy Economics*, 37, 16-28.
- Abbe, H., & Gbame, H. D. (2019). Prix des matières premières d'exportation et taux de change effectifs reels dans les pays de l'UEMOA. *European Scientific Journal*, 15(1).
- Lardic, S., & Mignon, V. (2002). *Econométrie des séries temporelles macroéconomiques et financières*.
- Mignon, V. (2022). *Econométrie : Théorie et applications*.
- Charpentier, A., Flachaire, E., & Ly, A. (2018). Économétrie & Machine Learning. [HAL](#).
- Kraevskiy, A., Prokhorov, A., & Sokolovskiy, E. (2024, 4 avril). *Early warning systems for financial markets of emerging economies*. arXiv.org. <https://arxiv.org/abs/2404.03319>
- Showalter, S., & Gropp, J. (2019, 11 septembre). *Validating Weak-form Market Efficiency in United States Stock Markets with Trend Deterministic Price Data and Machine Learning*. [arXiv.org](#).
- Magris, M., Shabani, M., & Iosifidis, A. (2022, 7 mars). *Bayesian Bilinear Neural Network for Predicting the Mid-price Dynamics in Limit-Order Book Markets*. [arXiv.org](#).
- Hanetho, J. (2023, 14 juin). *Deep Policy Gradient Methods in Commodity Markets*. arXiv.org. <https://arxiv.org/abs/2308.01910>
- Mohammadi, S., & Hesamzadeh, M. R. (2022, 11 mars). *Econometric Modeling of Intraday Electricity Market Price with Inadequate Historical Data*. arXiv.org. <https://arxiv.org/abs/2203.06077>
- Narajewski, M., & Ziel, F. (2020). Econometric modelling and forecasting of intraday electricity prices. *Journal Of Commodity Markets*, 19, 100107.
- Hanetho, J. (2023b, août 10). *Commodities Trading through Deep Policy Gradient Methods*. [arXiv.org](#).
- Bourbonnais R. (2000), *Econométrie*, DUNOD.
- Hurlin, C. (s. d.). *Econométrie Appliquée Séries Temporelles*.
- Charpentier, A. (s. d.). *Séries temporelles applications et théorie*.
- Colletez, G. (s. d.). *Introduction à la cointégration*.
- Hastie, T., Tibshirani, R., & Friedman, J. H. (2013). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*.
- Vodounou, C. (1997). *Essais en économétrie théorique et en économétrie de la finance appliqués aux modèles dynamiques*.
- Giraud, P., & Ollivier, T. (2015). *L'économie des matières premières*. Editions La Découverte.
- Hurlin, C. & Mignon, V. (2022). Chapitre 4. Séries temporelles : une introduction. C. Hurlin & V. Mignon (Dir), *Statistique et probabilités en économie-gestion* (pp. 90-113). Paris : Dunod.
- Uctum, R. (2007). Économétrie des modèles à changement de régimes : un essai de synthèse. *L'Actualité économique*, 83(4), 447-482.
- De Truchis, G., & Dumitrescu, E. (2016). *Économétrie non-linéaire : modèles à changement de régime markovien*.

Kilian, L., & Murphy, D. P. (2013). THE ROLE OF INVENTORIES AND SPECULATIVE TRADING IN THE GLOBAL MARKET FOR CRUDE OIL. *Journal Of Applied Econometrics*, 29(3), 454-478.

Hamilton, J. D. (1994). *Time Series analysis*. Taylor & Francis US.

Zhang, Z., & Li, S. F. (2010). Forecasting Volatility in Financial Markets. *Key Engineering Materials*, 439-440, 679-682.

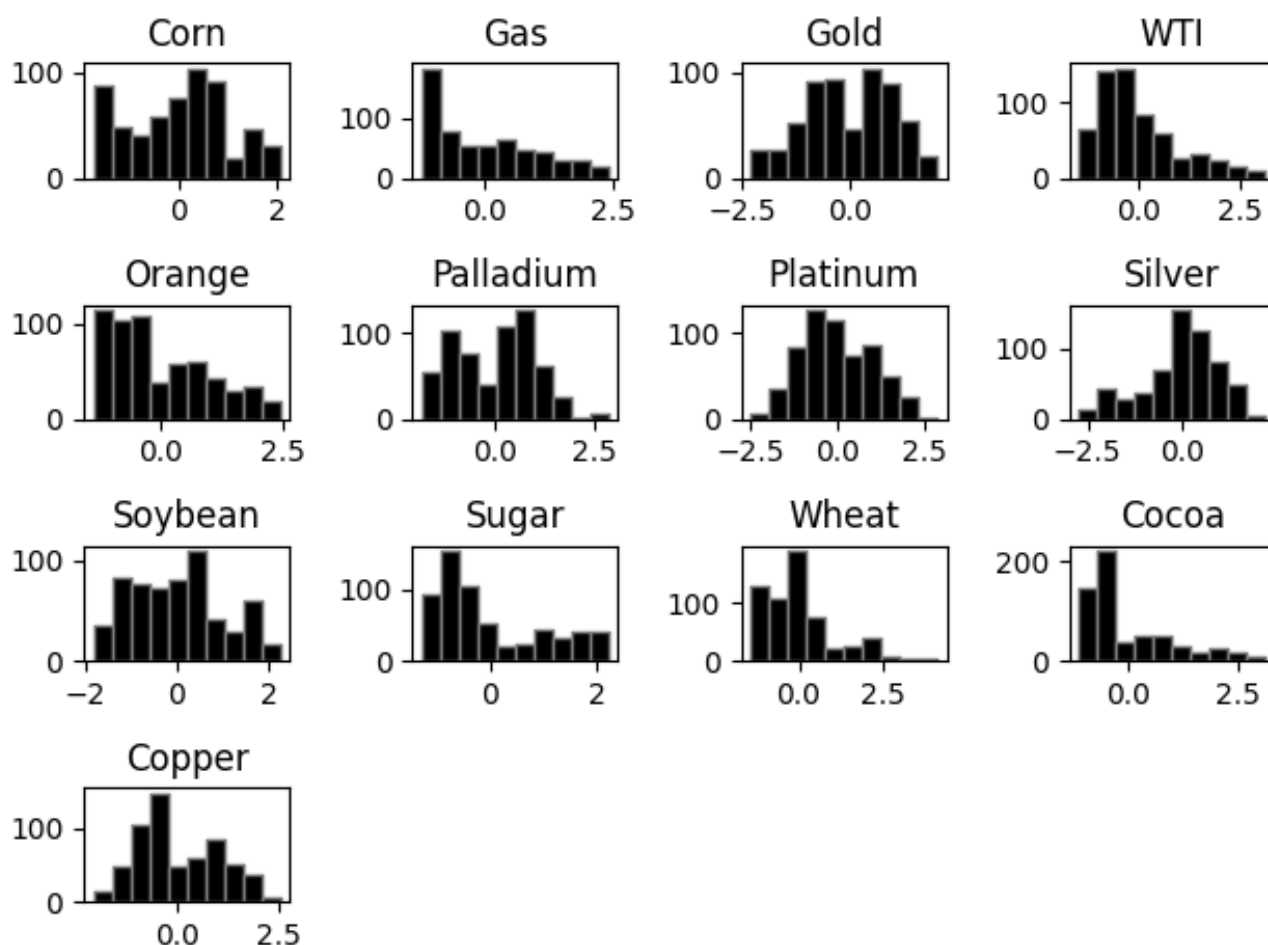
Fama, E. F., & French, K. R. (1987). Commodity Futures Prices : Some Evidence on Forecast Power, Premiums, and the Theory of Storage. *The Journal Of Business* 60(1), 55.

Baker, H. Kent, Greg Filbeck, and Jeffrey H. Harris (eds), 'Commodities : An Overview', in H. Kent Baker, Greg Filbeck, and Jeffrey H. Harris (eds), *Commodities : Markets, Performance, and Strategies* (New York, 2018 ; online edn, Oxford Academic, 22 Mar. 2018



Chuffart, T. (2015). Selection Criteria in Regime Switching Conditional Volatility Models. *Econometrics*, 3(2), 289-316.

7 Annexes

- *For descriptives statistics*



- *For LSTM*



- *For Gradient Boosting*

